


**ANALISIS SAMPEL DARAH DENGAN MACHINE LEARNING PREDICTIVE
ALGORITHMS UNTUK MEMPREDIKSI PENYAKIT GAGAL GINJAL**



Computational Biology - Kelompok 7

Oleh:

2602090731 - Jesika Purnomo

2602111723 - Matheus Ariel Reinhart Sidharta

2602084016 - Misia Callista Abdipatra

2602091053 - Raffa Winters

PROGRAM STUDI COMPUTER SCIENCE

SEMESTER GENAP 2023/2024

Analisis Sampel Darah dengan Machine Learning Predictive Algorithms untuk Memprediksi Penyakit Gagal Ginjal

1st Jesika Purnomo

School of Computer Science

Bina Nusantara University

Tangerang, Indonesia

jesika.purnomo@binus.ac.id

2nd Matheus Ariel Reinhart Sidharta

School of Computer Science

Bina Nusantara University

Tangerang, Indonesia

reinhart.sidharta@binus.ac.id

3rd Misia Callista Abdipatra

School of Computer Science

Bina Nusantara University

Tangerang, Indonesia

misia.abdipatra@binus.ac.id

4th Raffa Winters

School of Computer Science

Bina Nusantara University

Tangerang, Indonesia

raffa.winters@binus.ac.id

ABSTRAK

Ginjal adalah salah satu organ terpenting dalam tubuh manusia. Fungsi ginjal adalah untuk menyaring darah dan membuang limbah hasil metabolisme tubuh. Ketika ginjal sudah tidak bisa lagi menjaga keseimbangan darah dan tekanan darah, area-area lain tubuh akan terpengaruhi sehingga penyakit ginjal dapat menyebabkan masalah kesehatan yang serius. Salah satu langkah krusial dalam penanganan dan pencegahan penyakit ginjal adalah melalui deteksi dini. Sudah terdapat metode tradisional pendeteksian dini penyakit ginjal seperti *screening* hipertensi dan DM (Diabetes Melitus), namun masih terdapat batasannya. Salah satu opsi untuk meningkatkan performa dan akurasi

deteksi dini penyakit ginjal adalah dengan mengimplementasi teknologi *Artificial Intelligence* atau Kecerdasan Buatan. Draft paper ini mengusulkan metode baru untuk pendeteksian dini penyakit ginjal melalui analisis sampel darah dengan machine learning predictive algorithms.

Keyword - Sampel Darah, Gagal Ginjal, Predictive Algorithms, Machine Learning, Analisis

I. PENDAHULUAN

Penyakit Ginjal Kronis (CKD) merupakan kondisi yang membuat ginjal gagal berfungsi seiring dengan berjalannya waktu. Ginjal membantu tubuh manusia untuk dapat menyaring darah dan membantu tubuh manusia untuk membuang hasil dari

metabolisme yang tidak diperlukan oleh tubuh melalui urin. Ginjal merupakan organ utama yang mengontrol keseimbangan darah dan tekanan darah dalam tubuh manusia. Ginjal juga terlibat dalam produksi hormon yang penting di dalam tubuh manusia.

The Kidney Disease Improving Global Outcomes (KDIGO) mendefinisikan penyakit ginjal kronis (CKD) sebagai kelainan struktural dan fungsional ginjal yang menetap selama lebih dari tiga bulan [1]. Oleh karena itu, ginjal telah terbukti berperan penting di dalam tubuh manusia. Tetapi, ketika kondisi ginjal memburuk atau tidak baik, fungsi tubuh tersebut tidak lagi berfungsi secara efektif. Penyakit gagal ginjal kronis mempengaruhi hampir sekitar 10% dari populasi umum di seluruh dunia [2].

Gagal ginjal adalah suatu kondisi serius yang mempengaruhi kemampuan ginjal dalam menyaring darah terutama metabolisme protein di dalam tubuh manusia. Salah satu akibat utama dari gagal ginjal adalah Proteinuria, kondisi dimana terjadi kebocoran protein ke dalam urin. Hal ini dapat menyebabkan penurunan produksi protein yang penting untuk kesehatan dan fungsi tubuh.

Penyakit ginjal kronis (CKD) adalah masalah kesehatan global, memengaruhi 8 - 16% populasi yang ada di dunia [3,4]. Kerusakan ginjal adalah proses yang tidak dapat diubah. Semua bentuk pada penyakit ginjal dapat berkembang menjadi *End Stage Renal Disease* (ESRD, yang mungkin

memerlukan *Renal Replacement Therapy* (RRT) untuk sisa disfungsi pada ginjal [5,6].

Penelitian observasional menunjukkan bahwa tingkat perkembangan dan tingkat dari keparahan penyakit gagal ginjal bervariasi [7,8]. Maka dari itu diperlukan identifikasi dini secara akurat terhadap kelompok yang berisiko tinggi terkena penyakit ginjal. Hal tersebut untuk dapat menunda penurunan fungsi ginjal menjadi fokus utama dalam pengobatan ginjal [9-11].

Dengan semakin banyaknya kasus penyakit ginjal dan variasi tingkat keparahannya, diperlukan pendekatan yang terstruktur untuk menangani pasien dengan penyakit gagal ginjal. Model prediksi prognosis yang akurat dapat membantu medis dalam mengidentifikasi pasien yang berisiko tinggi. Strategi pengelolaan pasien dapat dipersonalisasi berdasarkan dengan hasil dari prediksi tersebut. Para peneliti telah melakukan berbagai penelitian untuk dapat mengidentifikasi faktor risiko penyakit dari gagal ginjal dan mengembangkan model prediksi risiko [12, 13].

Tujuan dari studi ini adalah untuk memahami berbagai model dalam pembelajaran mesin atau *Machine Learning* untuk memprediksi dini penyakit ginjal kronis. Selain itu, tujuan dari studi ini untuk menguji perbedaan model dalam pembelajaran mesin yang digunakan untuk prediksi penyakit gagal ginjal melalui analisis sampel darah. Ada berbagai pendekatan untuk dapat mengidentifikasi penyakit ginjal kronis, salah satu tekniknya

adalah *K-Nearest Neighbors* (KNN), *Decision Tree Classifier*, dan lainnya.

Studi ini menggunakan algoritma dalam pembelajaran mesin atau *Machine Learning* untuk memprediksi faktor risiko penyakit ginjal kronis. Dengan menggunakan pendekatan dari pembelajaran mesin diharapkan dapat membantu dalam pencegahan gagal ginjal, prediksi risiko gagal ginjal di masa depan, dan skalabilitas. Tingkat penyakit dari gagal ginjal kronis terus meningkat dari hari ke hari.

Terdapat banyak pasien gagal ginjal yang tidak mencari pengobatan dini saat ginjal masih dalam kondisi yang baik. Oleh karena itu, prediksi faktor risiko menjadi hal yang penting untuk dapat intervensi dini dan mencegah terjadinya komplikasi yang serius. Penelitian yang kami lakukan bertujuan untuk dapat mencari metode pembelajaran mesin yang lebih akurat di antara metode lainnya dalam memprediksi kemungkinan pasien menderita penyakit ginjal kronis, sehingga dapat memprediksi risiko penyakit.

II. TINJAUAN PUSTAKA

2.1 Machine Learning

Machine learning adalah salah satu alat yang manusia ciptakan untuk membuat kehidupan lebih nyaman. Arthur Samuel mendefinisikan *Machine Learning* sebagai area studi yang memberi komputer kemampuan untuk belajar tanpa diprogram secara eksplisit. Dalam konteks analitik, *Machine Learning* digunakan untuk membantu manusia untuk mengambil wawasan dari sebuah data [14].

Dalam bidang medis, machine learning muncul sebagai alat analitika baru yang memiliki potensi besar dalam memprediksi prognosis pasien serta mencari faktor - faktor risiko dalam kemajuan sebuah penyakit [15]. Pembelajaran mesin atau *Machine Learning* juga membuka jalan bagi para ahli medis untuk meningkatkan efektifitas dalam praktek medis seperti mempelajari tisu makhluk hidup secara *in vivo* dan deteksi dini [16].

2.2 Metode Tradisional

Penyakit gagal ginjal adalah penyakit gradual sehingga gejala-gejalanya tidak timbul dari awal melainkan timbul secara perlahan-lahan. Oleh karena itu, dibutuhkan pendeteksian dini penyakit ginjal agar pasien bisa segera mengubah cara hidup dan meminimalisir faktor-faktor penyebab penyakit ginjal [17]. Saat ini, deteksi dini penyakit ginjal mencakup beberapa metode seperti:

1. Pemantauan hipertensi melalui pengukuran tekanan darah.
2. Pemantauan tingkat kreatinin melalui pemeriksaan darah.
3. Pemeriksaan urin untuk mendeteksi protein (Proteinuria).

Namun, metode-metode di atas memiliki beberapa keterbatasan yang dapat mengurangi akurasi pendeteksian. Salah satu keterbatasan tersebut adalah tingkat SCr (*serum creatinine*) dalam darah yang tidak selalu menggambarkan seberapa parah penyakit ginjal yang ada [18]. Komponen penting lainnya dalam deteksi dini penyakit

ginjal merupakan estimasi GFR (Glomerular filtration rate) dan tingkat kreatinin dan cystatin C. Namun terdapat korelasi non-linear di antara kreatinin dan cystatin C terhadap GFR sehingga perubahan kecil pun pada variabel-variabel tersebut dapat berdampak besar pada perhitungan GFR sehingga hasil yang didapati juga tidak sepenuhnya akurat [19]. Metode pendeteksian dengan rasio albumin-kreatinin memiliki keterbatasan dimana perbedaan *tissue* otot masing-masing individu menjadikan penderita penyakit ginjal bersifat non-*albuminuric* tidak langka juga. Hal ini dapat sering ditemukan pada pasien dengan diabetes tipe 2. Oleh karena itu, pendeteksian dini dengan rasio albumin-kreatinin atau albuminuria menjadi indikator yang kurang dapat diandalkan [20].

III. METODOLOGI

Kami menggunakan beberapa langkah dalam penelitian ini. Setiap langkahnya akan dijelaskan sebagai berikut.

3.1 Deskripsi Data

Data description adalah proses pengumpulan dataset yang relevan untuk melakukan analisis. Data yang kami diambil berasal dari kaggle dan mengandung beberapa informasi yang dapat digunakan untuk memprediksi penyakit ginjal. Dataset untuk penelitian ini terdiri dari 399 kasus dengan masing-masing 26 atribut.

3.1.1 Data Preprocessing

Pada bagian preprocessing, noise data yang terdapat dalam dataset harus

dihilangkan dan mengubah kumpulan data tidak terstruktur menjadi semi terstruktur agar pengolahan lebih lanjut untuk mencapai hasil yang lebih baik. Dataset yang memiliki nilai null akan kami gantikan dan isi dengan value, agar tidak mengganggu saat pembuatan model di step berikutnya. Penskalaan Fitur dan Normalisasi digunakan untuk meningkatkan kecepatan konvergensi suatu algoritma serta meminimalkan waktu pelatihan.

3.2 Teknik Machine Learning

3.2.1 K-Nearest Neighbors (KNN)

KNN merupakan sebuah algoritma pembelajaran mesin yang bekerja dengan regresi untuk mendefinisikan k titik terdekat dari titik data baru. Klasifikasi menggunakan KNN adalah menentukan kelas tetangga terdekatnya, sedangkan untuk regresi nilai prediksi dihitung dari median tetangga terdekat. Algoritma KNN tidak membutuhkan pelatihan dan cocok untuk digunakan dalam dataset kecil.

3.2.2 Decision Tree Classifier

Decision Tree Classifier adalah algoritma pembelajaran mesin untuk memisahkan data ke dalam suatu subset berdasarkan fitur yang paling signifikan. Algoritma ini membentuk struktur seperti pohon yang memiliki node, dimana setiap node merepresentasikan sebuah fitur. Algoritma ini membagi data secara rekursif berdasarkan atribut yang menghasilkan informasi tertinggi, sehingga membentuk aturan-aturan yang dapat digunakan untuk memprediksi kelas data baru.

3.2.3 Random Forest Classifier

Random Forest Classifier memiliki tiga hyperparameter utama yang harus ditetapkan sebelum pelatihan: ukuran node, jumlah tree, dan fitur yang diambil sampelnya. Setiap tree terdiri dari sampel data dari satu set pelatihan, dan sepertiganya disisihkan sebagai data uji.

3.2.4 AdaBoost Classifier

AdaBoost atau Adaptive Boosting Classifier merupakan algoritma pembelajaran mesin berbasis ensemble yang meningkatkan akurasi prediksi dengan menggabungkan sejumlah model sederhana. Algoritma ini bekerja secara iteratif. Algoritma ini bekerja secara iteratif, di mana setiap model baru fokus pada kesalahan yang dibuat oleh model sebelumnya dengan memberikan bobot lebih tinggi pada data yang salah diklasifikasikan. Hasil akhirnya adalah kombinasi dari semua model dengan bobot yang ditentukan berdasarkan keakuratan masing-masing. AdaBoost sangat efektif dalam mengurangi bias dan varians, meningkatkan kinerja model secara keseluruhan, terutama pada dataset yang sulit.

3.2.5 Gradient Boosting Classifier

Gradient Boosting Classifier adalah algoritma ensemble yang meningkatkan akurasi prediksi dengan menambahkan model-model lemah secara bertahap. Setiap model baru akan memperbaiki kesalahan dari model sebelumnya dengan mengoptimalkan fungsi loss. Hasil akhirnya adalah kombinasi dari semua model yang meminimalkan kesalahan total. Gradient

boosting sangat efektif untuk klasifikasi dan regresi, tetapi membutuhkan waktu lebih banyak untuk diproses dan rentan terhadap overfitting jika tidak diatur dengan baik.

3.2.6 Stochastic Gradient Boosting

Stochastic Gradient Boosting merupakan varian dari Gradient Boosting yang memperkenalkan element acak untuk meningkatkan kinerja dan mengurangi overfitting. Algoritma ini tidak menggunakan seluruh dataset, tetapi menggunakan subset acak pada setiap iterasi. Metode ini mempertahankan efektivitas Gradient Boosting dalam menangani data kompleks dan non-linear.

3.2.7 XgBoost

XgBoost atau Extreme Gradient Boosting adalah algoritma yang sangat efisien dan optimal untuk kinerja tinggi. XgBoost merupakan implementasi dari Gradient Boosting yang mencakup berbagai pengoptimalan teknik, seperti kemampuan menangani missing values secara otomatis. Algoritma ini sangat bagus untuk menangani dataset besar dan kompleks dengan cepat. XgBoost juga menyediakan berbagai hyperparameter yang dapat disesuaikan untuk mengoptimalkan kinerja model lebih lanjut.

3.2.8 CatBoost

CatBoost atau Categorical Boosting adalah algoritma yang menangani data dengan fitur kategorikal secara efisien. CatBoost menggabungkan teknik-teknik pengoptimalan seperti pemrosesan paralel, regulasi untuk mengurangi overfitting, dan

penanganan missing values secara otomatis. Algoritma ini memberikan akurasi yang tinggi dengan waktu pelatihan yang relatif cepat.

3.2.9 Extra Tree Classifier

Extra Tree Classifier adalah algoritma yang menggunakan banyak pohon keputusan untuk meningkatkan akurasi prediksi. Berbeda dengan Random Forest yang menggunakan split terbaik untuk setiap pohonnya, Extra Tree secara acak mengambil split. Extra Tree lebih cepat dilatih dibandingkan dengan Random Forest karena mengurangi jumlah kalkulasi yang diperlukan untuk menentukan titik split terbaik.

3.2.10 LightGBM Classifier

Light Gradient Boosting Machine Classifier adalah algoritma yang berbasis ensemble yang dioptimalkan untuk kecepatan dan skala besar. LightGBM Classifier menggunakan pendekatan leaf-wise atau pertumbuhan berdasarkan daun, yang memungkinkan pertumbuhan vertikal pohon. Hal ini memungkinkan LightGBM bekerja dengan cepat dan efisien pada dataset besar dengan fitur-fitur kategori dan mempertahankan akurasi tinggi. LightGBM sering digunakan karena kecepatan, skalabilitas serta akurasi yang tinggi.

3.3 Pengukuran Performa

Kami menggunakan analisa performa menggunakan Confusion Matrix. Confusion matrix merupakan tabel yang digunakan untuk mengevaluasi kinerja

model klasifikasi dalam pembelajaran mesin. Tabel matrik ini menunjukkan jumlah prediksi yang benar dan salah untuk setiap kelas.

Confusion matrix terdiri atas beberapa elemen, yakni:

- True Positive (TP): Jumlah prediksi positif yang benar.
- False Positive (FP): Jumlah prediksi positif yang salah.
- True Negative (TN): Jumlah prediksi negatif yang benar.
- False Negative (FN): Jumlah prediksi negatif yang salah.

True positive dan true negative diklasifikasikan dengan benar, false positive dikategorikan sebagai kesalahan tipe I, sedangkan false negative diklasifikasikan sebagai kesalahan tipe II.

Kami menggunakan beberapa parameter matriks yang berbeda untuk evaluasi model kami, termasuk akurasi, presisi, recall, dan F1-score. Kita dapat menghitung ukuran kinerja ini dengan menggunakan persamaan berikut.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F - measure = \frac{2 \times Precision \times Recall}{Precision + Recall}$$

Kumpulan data dibagi menjadi dua bagian: 70% untuk pelatihan dan 30% untuk tujuan pengujian. Pengukuran ini diterapkan

ke semua pengklasifikasi dengan tujuan melihat perbandingan antar model.

IV. HASIL

Setelah melakukan proses dasar dimulai dari *Data Description*, *Data Preprocessing*, *Data Understanding*, dan masuk ke penerapan model Machine Learning. Kami melakukan analisis untuk mengidentifikasi model mana yang paling akurat dan efektif dalam memprediksi penyakit gagal ginjal berdasarkan dataset yang diberikan.

Untuk mencapai itu, kami menggunakan beberapa metrik performa antara lain akurasi, presisi, recall, dan F1-score untuk mengevaluasi performa tiap modelnya, hasilnya sebagai berikut:

Model	Precision	Recall	F1-Score	Accuracy (%)
KNN	0.54	0.60	0.75	63.333
Decision Tree	0.96	0.90	0.92	94.167
Random Forest	0.98	0.94	0.96	96.667
Ada Boost	0.96	0.94	0.95	95.833
Gradient Boosting	0.94	0.94	0.94	95.000
Stochastic Boosting	0.96	0.92	0.94	95.000
XgBoost	0.96	0.94	0.95	95.833
Cat Boost	0.96	0.94	0.95	95.833
Extra	0.98	0.96	0.97	97.500

Tree				
LGBM	0.98	0.94	0.96	98.333

Tabel 1. Analisis Komparatif dan Performa tiap model (%)

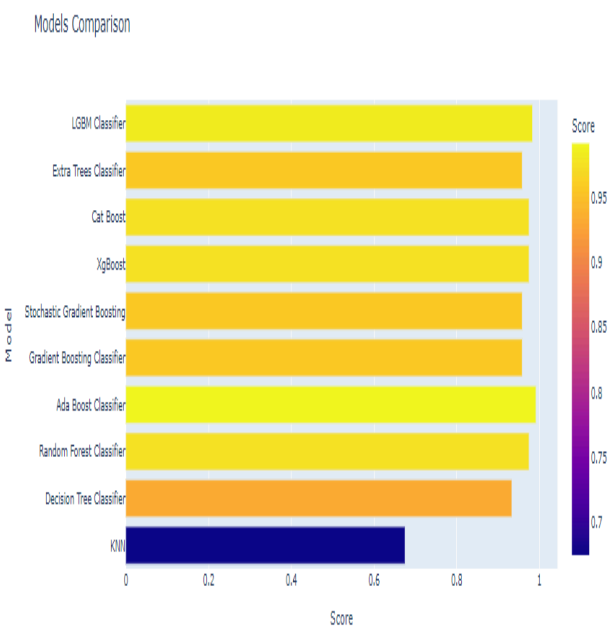


Figure 1. Perbandingan performa model dalam bar chart.

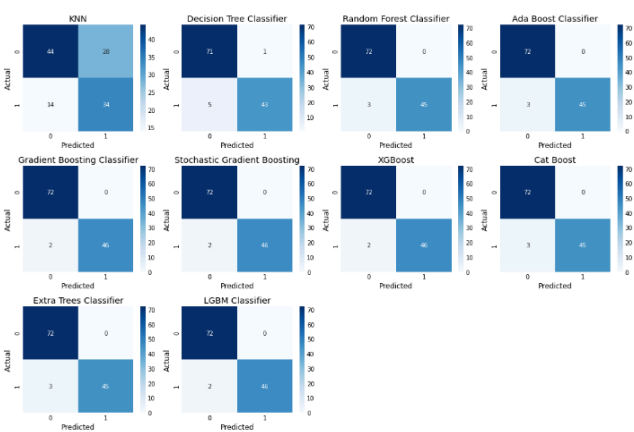


Figure 2. Perbandingan performa model dalam Confusion Matrix.

Dari tabel dan gambar yang telah disediakan sebelumnya dapat disimpulkan

bahwa model LGBM Classifier memiliki tingkat akurasi untuk prediksi Penyakit Gagal Ginjal yang tertinggi dibandingkan 9 model lainnya.

V. KESIMPULAN

Prevalensi Penyakit Gagal Ginjal meningkat secara global, dan diagnosis penyakit secara manual menjadi tantangan karena kurangnya gejala dini yang jelas, yang dapat menyebabkan telatnya penanganan. Oleh karena itu, terdapat kebutuhan mendesak untuk menetapkan metode yang efektif untuk prediksi dini Penyakit Gagal Ginjal. Dengan menggunakan pendekatan Machine Learning seperti 10 model prediksi yang telah kami sebutkan sebelumnya, kami mendapatkan skor akurasi 98.333%. Dari skor yang cukup menjanjikan tersebut, kami dapat menyimpulkan bahwa penggunaan model prediksi LGBM dapat membantu ahli bidang medis dalam mendiagnosa dini Penyakit Gagal Ginjal, untuk mencegah penyakit gagal ginjal pada taraf yang lebih tinggi..

REFERENSI

- [1] Kidney Disease: Improving Global Outcomes (KDIGO) CKD Work Group. KDIGO. "Clinical practice guideline for the evaluation and management of chronic kidney disease." *Kidney Int Suppl* 2013.3 (2012): 1-150.
- [2] Modglin, L. (n.d.). *Kidney disease statistics* 2023.
- [3] Coresh J, Turin TC, Matsushita K, et al. Decline in estimated glomerular filtration rate and subsequent risk of end stage renal diseases and mortality. *JAMA*. 2014;**311**(24):2518–2531. doi: 10.1001/jama.2014.6634.
- [4] Jhac V, Garcia G, Iseki K, et al. Chronic kidney disease: global dimension and perspective. *Lancet*. 2013;**382**:260–272. doi: 10.1016/S0140-6736(13)60687-X1
- [5] World Health Organization. World Health Statistics 2019 Monitoring Health for The SDGs, Sustainable Development Goals. Geneva: World Health Organization; 2019.Licence: CCBY-NC-SA3.0IGO.<https://apps.who.int/iris/bitstream/handle/10665/324835/9789241565707-eng.pdf?sequence=9&isAllowed=y>.
- [6] 4. GBD Chronic Kidney Disease Collaboration Global, regional, and national burden of chronic kidney disease, 1990–2017: a systematic analysis for the Global Burden of Disease Study. *Lancet*. 2017;**2020**:1–25. doi: 10.1016/S0140-6736(19)32977-0.
- [7] Helena U, Zacharias MA, et al. A novel metabolic signature to predict the requirement of dialysis or renal transplantation in patients with chronic kidney disease. *J Proteome Res*. 2018;**2**:1–42. doi: 10.1021/acs.jproteome.8b00983
- [8] Fang Z, Avrum G, Djordje G, Jelena G, Zoran O. Use of disease embedding technique to predict the risk of progression to end-stage renal disease. *J*

Biomed Inform. 2020;**105**:103409. doi: 10.1016/j.jbi.2020.103409

[9] KDIGO workgroup KDIGO2012 clinical practice guideline for the evaluation and management of chronic kidney disease. *Kidney Int Suppl.* 2013;**3**:1–150. doi: 10.1038/kisup.2012.73.

[10] UK National Institute of Health and Clinical Excellence chronic kidney disease early identification and management of chronic kidney disease in adults in primary and secondary care. *NICE Clin Guidel.* 2014;**182**:1–59.

[11] KDOQI Workgroup KDOQI clinical practice guideline for nutrition in CKD: 2020 update. *Am J Kidney Dis.* 2020;**76**:S1–S107.doi: 10.1053/j.ajkd.2020.05.006.

[12]. Navdeep T, Georgios DK, Lesley AI, et al. Risk prediction models for patients with chronic kidney disease: a systematic review. *Ann Intern Med.* 2013;**158**:596–603. doi: 10.7326/0003-4819-158-8-201304160-00004. 14.

[13] Chava LR, Ype J, Friedo WD, Merel D. Towards the best kidney failure prediction tool: a systematic review and selection aid. *Nephrol Dial Transplant.* 2020;**35**:1527–1538. doi: 10.1093/ndt/gfz018.

[14] Mahesh, B. (2020). Machine learning algorithms-a review.

International Journal of Science and Research (IJSR).[Internet], 9(1), 381-386.

[15] Peter BJ, Lars JJ, Søren B. Mining electronic health records: towards better research applications and clinical care. *Nat Rev Genet.* 2012;**13**:395–405. doi: 10.1038/nrg3208.

[16] Magoulas, G. D., & Prentza, A. (1999). Machine learning in medical applications. In *Advanced course on artificial intelligence* (pp. 300-307). Berlin, Heidelberg: Springer Berlin Heidelberg.

[17] Mano, D., Ezra, P. J., Marcella, A., & Firmansyah, Y. (2023). Kegiatan Pengabdian Masyarakat dalam Rangka Edukasi Masyarakat Terhadap Hipertensi serta Deteksi Dini Penyakit Gagal Ginjal Sebagai Komplikasi dari Hipertensi. *JURNAL PENGABDIAN MASYARAKAT INDONESIA*, 2(2), 34-45.

[18] Cho, S. Y., & Hur, M. (2018). Neutrophil gelatinase-associated lipocalin as a promising novel biomarker for early detection of kidney injury. *Annals of Laboratory Medicine*, 38(5), 393.

[19] Mizdrak, M., Kumrić, M., Kurir, T. T., & Božić, J. (2022). Emerging biomarkers for early detection of chronic kidney disease. *Journal of personalized medicine*, 12(4), 548.

[20] Lin, C. H., Chang, Y. C., & Chuang, L. M. (2016). Early detection of diabetic kidney disease: Present limitations and future perspectives. World journal of diabetes, 7(14), 290.

[21] Dataset: Chronic Kidney Disease Dataset - Kaggle

(<https://www.kaggle.com/datasets/mansoordaku/ckdisease>)

[22] Code: Prediksi Penyakit Gagal Ginjal Kronis - Google Colab (<https://colab.research.google.com/drive/1874wyrzh7V5xEKtHhywYfmQ4awPAIYwT?usp=sharing>)